

MetaGenomicAssistant

DATA REFINEMENT STRATEGY & QUALITY ASSURANCE

By Youssef Lamrabi


Metric Status: **Highly Accurate**
Optimization: **-33% Noise Removed**

BRUT INITIAL
15,293
Records total

RÉDUCTION FLUX
-31%
Cross-Domain Filter


DATASET FINAL
10 500
Expert Instructions

1. DISTRIBUTION INITIALE DES SOURCES (ÉTAT BRUT)




Analyse : Biostars et la littérature scientifique dominent le volume initial. La diversité des sources assure une couverture large des problématiques bioinformatiques.

2. ANALYSE FILTRE : QIIME2 FORUM




Focus : Excellente pertinence (97%). Le filtre a permis de conserver l'intégrité des workflows QIIME2 tout en éliminant les rares cas hors-sujet.

3. ANALYSE FILTRE : BIOCONDUCTOR




Focus : Filtrage agressif des données Omics générales (RNA-Seq/Microarray) pour ne garder que les outils de métagénomique stricte.


4. RÉPARTITION TECHNIQUE (BIOSTACKEXCHANGE)



5. COMPOSITION DU DATASET EXPERT (FINAL)



6. SYNTHÈSE GLOBALE DE PERTINENCE (QUALITY ASSURANCE)



"Le passage de 15k à 9.4k transforme un dataset bruyant en une base de connaissance spécialisée prête pour le Fine-Tuning."

✅ **RÈGLE 1 — INCLUSION** (*Liste Blanche*)

Le record doit **obligatoirement** contenir au moins un mot-clé lié à la métagénomique pour être conservé dans le dataset.

Exemples de mots-clés inclus : 16S • Kraken • Metaspades • QIIME2 • amplicon • metagenome • OTU • microbiome etc

❌ **RÈGLE 2 — EXCLUSION** (*Liste Noire*)

Le record ne doit contenir **aucun** mot-clé appartenant à d'autres domaines omiques, même s'il satisfait la règle 1.

Exemples de mots-clés exclus : RNA-Seq • GWAS • Proteomics • Microarray • ChIP-Seq • ATAC-Seq • scRNA • WGS etc